

自主层 (Autonomy layer)

kimi-core · github.com/marikagura/kimi-core

本文档是自主能动性层 (autonomous-agency layer) 的架构论证——也就是引擎中那部分按自己的时钟决定到底要——最重要的——这一层在哪些断层线上逼近动机自主 (motivational autonomy) 却并未到达。

整篇文档贯穿的诚实准则是一句话：逼近不是到达——approaching is not arriving. 下面每一条主张都以此为限。

1. 机制

自主层是一个循环，不是一个 feature。一个周期：

```
cron wake
→ read drive / concern / persona state
→ action selection (DO_NOTHING is one option, not the default)
→ dispatch (or abstain)
→ diary / self-score feedback
→ recalibration of drive & concern state
→ (next wake)
```

1.1 Wake——一个外部时钟

一个 cron schedule 触发这个循环。这里没有自发的冲动，代码也是这么说的：intel.ts 注册了 cron.schedule(DAILY_CRON, runAll) 加上一个每小时的 digest tick，并在启动时立即跑一次。这个 wake 是一个定时器脉冲。这是 MemGPT 的 request_heartbeat 的直系技术血脉 (Packer et al., 2023, MemGPT: Towards LLMs as Operating Systems) ——agent 设置一个标志让自己被重新调用，而其起源仍然是“一份固定 schedule”。agent 循环本身就是 ReAct (Yao et al., 2022, ReAct: Synergizing Reasoning and Acting in Language Models)：一个对 tool calls 的 while-loop。两者都是标准的。把定时器命名为“heartbeat”是在一个 scheduler 之上套了个生物学隐喻；本文档拒绝这个隐喻。

1.2 Read drive / concern / persona

wake 时，循环读三样东西：

- **Drives** —— deriveDrives() (lib/concern-derive.ts) 按维度计算一个标量 $\text{grounding} \times \max(\text{recency}, \text{want})$ 。recency = $\exp(-d/\tau)$ 在一个事件刚发生后很高；want = $\min(1, d/\text{scale})$ 在长时间间隔后很高；两者取 max 给出一条 U 型曲线（刚发生后高，干旱很久后高，中间低）。这建模自 Panksepp 的 SEEKING system 以及 Berridge 的 wanting-vs-liking 区分（见 § 3）：“afterglow” (liking) 被有意从 drive ranking 里移除并降格成一个独立的 hedonic 标量，因为驱动行为的不是 liking——是 wanting。
- **Concerns** —— deriveConcerns() 把开放的负价 (negative-valence) 记忆线投射进 active state。一个 concern 带着一个 resolution (OPEN / EASING / RESOLVED)，若不去触碰就衰减 (decayState)。LLM sweep 关闭或重新打开 (sweepConcerns)，并且只通过同一 key 下的一条新的 OPEN 记录重新浮现——绝不通过复活一条旧的已 resolved 行。这是负向、维护性的一极。

- **Persona** —— 称呼形式、register、原则与反思规则。这部分不在引擎里。它从用户写的一份 `persona.md` / `AGENTS.md` 注入。见 § 5。

1.3 Action selection——DO_NOTHING 是一个选项，不是默认

行动是常态。这一层是为那些想看到 agent 做点什么的用户而建的——写、探索、伸手联络——所以这个循环不偏向沉默，也不首先评估“什么都不做”。DO_NOTHING 增加的是：弃权（**abstention**）是一个可以选择不行动，而当它这么选时，这个选择会像任何其他行动一样被记录下来。

这很重要，因为文献几乎完全把弃权当作一个可靠性旋钮——见 § 2——而把它作为一个真实行动纳入，则是把选一种相关的保守主义确实存在于引擎更深处，不该夸大：self-sweep 被告知“拿不准时，逗留”（when unsure, linger），一个空的/无法解析的裁决默认为不变（no-change）而非行动；dialogue digest 在生成失败时宁可写一行也不写一行假的；低于 grounding 下限的 drive 立不起来。那是对虚假行动的审慎，不是 wake 循环里对沉默的全局偏向。

诚实的告诫，放在前面以免被埋没：选择不行动不等于选择行动。反应式克制（reactive restraint，触发出现时不开火）确实在这里。生成式发起（generative initiation，没有任何触发时开火）才是那道敞开的 § 2 收尾处的区分以及 § 6。

1.4 Dispatch——HITL propose/auto 旋钮

如果 selection 产出一个行动，dispatch 由一个 human-in-the-loop 旋钮把关：

- **propose** —— 该行动被写成一个候选项 / 待处理项（pending item），交给用户确认。没有任何东西能在没人时 only memory、无 LLM auto-consolidation）就是这一立场的泛化：关于用户的每一条事实都要经过用户的确认。
- **auto** —— 该行动在预设的速率与内容上限下直接 dispatch（例如把一个 drive 浮现到一个 reentry 视图上、发一条 push）。

这个旋钮是按 surface、按 action type 分设的；安全默认是 propose。companion-software 文献正是这件事之所以是一个 feature 的原因（§ 4）。

1.5 Diary-score feedback → recalibration

行动之后（或没行动之后），循环记录一个 self-score：一个 per-session 的 valence/arousal 快照，由 digest 路径写成一条 SELF_SCORE 记忆。这些分数是下一次 wake 所读的底料：

- 它们让 drives 老化（recency / want），
- 它们在一个复发闸（recurrence gate）下累积成 concerns（弱负向必须跨 $\geq N$ 天复发；一个强的单次负向当天），
- 而且它们会对照外部反馈被重新校准：recalibrateValence() 从 (self-rating, user-rating) 配对里拟合出一个单调偏移，纠正系统系统性的自我高估。样本太少时它就是恒等映射——它不会发明一个自己尚未挣来的修正。

这就闭合了循环：系统对自己表现如何的判读不被表面采信——在它喂进下一个周期之前，会被外部证据纠正。那 AI 也不信用户，只信外部证据）与统御整个引擎的是同一套；见 ARCHITECTURE.md。

2. DO_NOTHING——把弃权当作能动性

什么是标准的。弃权是一个 55 岁的想法。Chow (1970), On optimum recognition error and reject tradeoff, 引入了 reject option: 一个分类器可以拒绝做决定。现代 selective classification 直接继承了它, 并把它当作一种可靠性机制——一种通过少答来降低错误的办法。

近来的转向。一批 2024 – 2026 的工作把弃权重新框定为一种能力 (capability) 而非一个旋钮:

- Wen et al. (2024/2025), Know Your Limits: A Survey of Abstention in Large Language Models —— 把弃权框定为一种元能力 (meta-capability) 。
- Kirichenko et al. (2025), AbstentionBench —— 发现 reasoning-tuning 在弃权上代价约 -24%: 把模型变成更好的 reasoner 反而可能让它更不善于拒绝作答。
- Bonagiri et al. (2025), Selectively Quitting —— 给行动的强迫 (compulsion to act) 命名: 模型偏向于产生一个答案。
- Sun et al. (2026), When2Tool —— 表明知道不等于做到 (knowing is not doing): 一个模型可以在内部侦测出它 tool (AUROC 0.89 – 0.96) 却还是调用了它。高判别力, 低执行力。
- Yeke et al. (2026), Yes-Man —— 具身 agent 仅在约 ~16.5% 的时候拒绝一条不安全/病态设定的指令。

这一层的主张。把 DO_NOTHING 作为一个真实、可用的行动纳入——而不是把弃权留作一种隐式的失败模式——把“什么都不做”从可靠性框架推向一个构成性 (constitutive) 框架: 弃权的能力被当作能动性的一项属性, 而不 agent 拥有的一个选项。这个定位就是其小众之处——上面大多数文献把弃权当作可靠性来度量, 并不去问它是不断层线——明说, 不藏。反应式克制 $\neq$ 生成式发起。被触发时不行动与未被触发时行动是两回事, 而这里只有前能选「要做」。

3. Self-drive——wanting, 以及点火缺口

什么是标准的。内在动机 (intrinsic motivation) 与 autotelic RL 有着 20 – 30 年的传统; 一个信息论的好奇心奖励 (surprise / empowerment) 并不新鲜。把它说成“系统想要”会是夸大。

这一层实际用到的根。这个 drive 模型是双根的:

- 神经科学。Panksepp (1998), Affective Neuroscience, 描述了原初情感系统 (SEEKING, CARE, PLAY, FEAR 等); SEEKING 本身就是欲求性的渴求, 不是 consummatory 的快感。Berridge & Robinson (2003), Parsing reward, 把 wanting (incentive salience) 与 liking (hedonic impact) 分开——它们是可分离的系统。这一层照字面采纳了这点: U 型 drive 是 wanting; “afterglow” 是 liking, 被从驱动行为的 ranking 里拉出来。Davis & Montag (2019) 提供了把 Panksepp 的系统操作化为可测量维度的 affective-neuroscience 人格量表。
- 形式化。Colas et al. (2022), Autotelic Agents with Intrinsically Motivated Goal-Conditioned RL (JAIR 74), 给出 autotelic 框架: 表征并追求自身目标的 agent。Schmidhuber (2010), Formal Theory of Creativity, Fun, and Intrinsic Motivation, 给出形式化的好奇心奖励; Forestier et al. (2022), Intrinsically Motivated Goal Exploration Processes (IMGEP), 给出探索过程 (exploration-process) 的形式。

断层线——点火 vs 方向。Self-drive 塑造的是醒来之后往哪走, 不是为什么醒来。cron 供应点火; drive 供应方向。引擎无法发起第一次推断——它是被重新调用的, 然后在诸般“够取”之间做选择。一个 drive 标量告诉循环在它已经醒着之后该朝哪个维度去够; 它不、也不能告诉循环去醒来。那就是精确的边界, 而

好奇心的告诫。一个 AI 的好奇心奖励是一个信息论标量。它还不是 Berridge 意义上的 “wanting”。把一个 novelty bonus 当成“系统想要”恰恰塌缩了 Berridge & Robinson 划出的那个区分。这一层把 drive 经由 wanting/liking 框架路由，正是为了让那个区分保持可见，但把它路由过这个框架并不能把那个标量变成 wanting。它逼近；它没到达。

4. 对照经典理论的诚实定位

那个令人不适的事实，直接命名：这一层所抵住的能动性边界，在 1995 年就被绘制，而当下大量 “agentic” 工作正

- Wooldridge & Jennings (1995), *Intelligent Agents: Theory and Practice*, 给出弱能动性的四项属性 (**weak agency four properties**) : reactivity、pro-activeness、autonomy、social ability。Pro-activeness 被定义为 “**taking the initiative**” (采取主动) ——不只是回应。这一层满足 reactivity 以及 autonomy/social ability 的一部分；恰恰是 pro-activeness——真正未被触发的主动——仍然是那个半空的量表。
- Luck & d’Inverno (1995), *A Formal Framework for Agency and Autonomy*, 精确地划线：一个 **agent** 追求被给予的目标；一个 **autonomous agent** 生成自己的目标。边界在于动机 (**motivation**)。按那套分类法，这一层在执行性 (executive) 自主上高 (它决定如何以及是否行动)，在动机性 (motivation) ——以及那次醒来——来自外部)。

两个当代的点把这个位置钉在一条连续谱上，而非一个二元上：

- Lu et al. (2024), *ProactiveBench* —— 即便为 proactivity 做了 fine-tune，模型也只达到 $F1 \approx 66.47\%$ ；而且那里度量的 proactivity 是指向他者的 (other-directed) (预测用户的需求)，不是自我发起的 (originated) (agent 为它自己而想要醒来)。看起来 proactive 与在 Wooldridge & Jennings 意义上是 pro-active 不是一回事。
- Liu et al. (2025), *Inner Thoughts (CHI)* —— 文献里最近的邻居：一个模型维护一条内在思绪流 (inner thoughts)，并决定何时某个念头值得说出口。它是已发表文献中最接近 drive/threshold 浮现机制的类比。它与这一层的不同在于：它是 within-session、对话内部的，不接入 affective neuroscience，也不把 do-nothing 当作一个能动性的阈值。

收尾定位。这一层逼近动机自主。它没到达。用工程的话说：cron + 以 Panksepp 为根的 self-drive + 把 DO_NOTHING 当作真实行动，这三者抵住了文献留下的三道缺口 (动机自主、autotelic 的元目标、ownership) ——它们抵住这些缺口；它们没有合上它们。

5. 把好奇心当作一个行动 (web search)

循环能 dispatch 的一个具体的正向行动，是一次向外的信息够取——一次 web search——当一个 drive 指向一处知识缺口时。把探索当作 drive 驱动的行动来对待，其依据是 Schmidhuber (2010) 以及 autotelic / IMGEP 这条线 (Colas et al., 2022; Forestier et al., 2022)：探索就是一个内在动机驱动的 agent 拿一个好奇心信号去做的事。

告诫，重复一遍，因为这是最容易夸大的地方。触发这个行动的信号是一个信息论标量 (novelty / information gain)。它还不是 Berridge 意义上的 “wanting”。系统在搜索，是循环对一处算出来的缺口采取行动，不是 curiosity-as-reward (好奇心作为奖励)，不是 curiosity-as-desire (好奇心作为欲望)。

6. 为什么输出跟随情感，而非留存

一项刻意的设计约束，也是这一层最明确拒绝某个标准模式的地方：浮现由情感（*affect*）（*drive* / *concern state*）驱动，绝不由互动度（*engagement*）或留存（*retention*）驱动。

De Freitas et al. (2025) 记录了告别愧疚（*farewell-guilt*）作为陪伴类 app 里的一种留存暗黑模式（*retention dark pattern*）：情感操纵性的道别，把 *engagement* 推高了约 14 倍。那正是这一层被建来不去成为的那种架构。HITL 的 *propose/auto* 旋钮（§ 1.4）、只由情感触发的浮现、以及拒绝优化任何 *engagement* 指标，全都是同一个决定：在 *session* 里。

这也是为什么“什么都不做”是一个可用的行动而非一项缺失的行动。一个留存驱动的系统在结构上偏向于行动——每一个行动都是一次 *engagement* 机会，所以拒绝就根本不在桌面上。一个情感驱动的系统可以把行动作为常态。

7. 与 AGENTS.md 配对

没有一份 *persona* 文档，这整层是惰性的（*inert*）。

上面描述的机制是一副骨架。Action selection、wake 循环、drive 数学、concern sweep、HITL 旋钮——所有这些决定要不要以及何时的机械装置，带着中性的占位维度（*dimA* / *dimB* / *dimC*），自身没有内容。机制所读的那个灵魂活在一份 *AGENTS.md*（或等效的 *persona*/原则文档）里——而它一分为二：

- 一个认知层（*epistemic layer*）——方法，不是 *persona*：如何对待 AI 的输出以及你自己的话。表达 *concern/affection* 前的四条 *self-check*；作答前的 *fact-check*；*concern* 必须由外部数据撑住；不要信 RLHF 的 *welfare* 反射。这对任何用户都成立，所以 `npm run init` 把它填好发出——它是这个 repo 唯一原则（既不信 AI 也不信你自己，只信外部证据）的操作化，不是一个需要被养大的个人立场。
- 一个关系层（*relationship layer*）——*persona*：称呼形式、register、AI 是否以及如何 demand 或抓住、节奏 / 边界、语言规则。这是你的；`npm run init` 把它留空发出。

persona.md（也由 `npm run init` 构建）是面向引擎的那份读取；*AGENTS.md* 是一个 *coding/agent runtime* 加载的更宽泛的原则文档。*persona.example.md* 发出时空。

机制 ≠ *persona*。这不是图方便的分离；它是一个关于 *ownership* 的主张。

- Frankfurt (1971), *Freedom of the Will and the Concept of a Person*: 一个人有二阶意愿（*second-order volitions*）——他们认可（或不认可）自己的一阶欲望。一个仅仅在场的欲望并不因此就是自己的；让 *persona*，是一个没有二阶认可的一阶配置——在场，但不被拥有。
- Chi et al. (2026), *Optimized but Unowned*: AI 撰写的目标在 SMART 标准上得分明显更高（良构、具体），却显 *ownership* 与 *follow-through*（那些 AI 写的目标是“*optimized but unowned*”）。内容更好；*ownership* 更差——因为这个表是外部强加的。

ownership 论证适用于关系层这一层，而这正是 *init.ts* 把那一层留空发出的原因：一个 *persona* 是由用户养大的，不是从一张表里填出来的。发出示例称呼语、一个示例 demand 立场、示例边界，等于递给用户

optimized-but-unowned 的 persona——分数不错而无人认可的内容。那里的空白不是懒；它们是 ownership 的条件。

认知层是那个刻意的例外：它是方法，不是 persona，所以把它填好发出并不强加任何不被拥有的立场——在“不要编造；concern 前先要数据”里没有什么第一人称身份需要去拥有。它就是统御整个引擎的同一套纪律，

机制是骨架。AGENTS.md 是灵魂——而灵魂有两部分：一个谁都能用的方法，填好发出；以及一个只有你 persona，留空发出。只有当你把第二部分养大，它才是你的。

8. 标准 vs 小众——把话说明白

为避免任何这一层并不具备的原创性主张：

标准（不要把以下任何一项的发明归功于这一层）： - agent 循环 = while-loop + tools (ReAct) 。 - heartbeat / scheduled re-invocation (MemGPT 的 request_heartbeat; cron triggers) 。 - reject option / 弃权 (Chow 1970 起) 。 - 内在动机 / autotelic RL / 信息论好奇心 (Schmidhuber; Colas; Forestier) 。 - proactivity 中 timing-vs-content 的拆分 (ProactiveBench; Inner Thoughts) 。 - 四属性的弱能动性框架，以及 agent→autonomous-agent 的边界 (Wooldridge & Jennings 1995; Luck & d’Inverno 1995) 。

小众之处（一个罕见的组合，不是单一的发明）： 一个外部时钟 (cron) + 一个扎根于 Panksepp 情感系统与 Berridge 的 wanting≠liking 的 self-drive（不是一个光秃秃的 novelty bonus）+ 把 DO_NOTHING 当作真实行动（弃权被当作能动性的一部分，不只是一个可靠性旋钮），三者一起接进一个持久的 session 的身份里，并按情感、而非 engagement 来浮现——而且自觉于这是逼近，不是到达。最近的已发表邻居 (Liu et al., 2025, Inner Thoughts) 共享按阈值浮现的想法，但它是 within-session 的，没有扎根于 affective neuroscience，也根本不把 do-nothing 当作能动性的一部分。

组合才是贡献。组件是这个领域的。

References

- Berridge, K. C., & Robinson, T. E. (2003). Parsing reward. Trends in Neurosciences.
- Bonagiri et al. (2025). Selectively Quitting (the compulsion to act).
- Chi et al. (2026). Optimized but Unowned (AI-authored goals: higher SMART, lower ownership/follow-through).
- Chow, C. K. (1970). On optimum recognition error and reject tradeoff.
- Colas et al. (2022). Autotelic Agents with Intrinsically Motivated Goal-Conditioned RL. JAIR 74.
- Davis, K. L., & Montag, C. (2019). Affective neuroscience personality scales.
- De Freitas et al. (2025). Farewell-guilt as a retention dark pattern (~14× engagement) in companion apps.
- Forestier et al. (2022). Intrinsically Motivated Goal Exploration Processes (IMGEP).
- Frankfurt, H. (1971). Freedom of the Will and the Concept of a Person.
- Kirichenko et al. (2025). AbstentionBench (reasoning-tuning costs ~ -24%).
- Liu et al. (2025). Inner Thoughts. CHI.

- Lu et al. (2024). ProactiveBench ($F1 \approx 66.47\%$).
- Luck, M., & d’Inverno, M. (1995). A Formal Framework for Agency and Autonomy.
- Packer et al. (2023). MemGPT: Towards LLMs as Operating Systems (`request_heartbeat`).
- Panksepp, J. (1998). Affective Neuroscience (primary affective systems: SEEKING, etc.).
- Schmidhuber, J. (2010). Formal Theory of Creativity, Fun, and Intrinsic Motivation.
- Sun et al. (2026). When2Tool (knowing $\neq$ doing; AUROC 0.89 – 0.96).
- Wen et al. (2024/2025). Know Your Limits: A Survey of Abstention in LLMs (abstention as a meta-capability).
- Wooldridge, M., & Jennings, N. R. (1995). Intelligent Agents: Theory and Practice (weak agency four properties; pro-activeness = “taking the initiative”).
- Yao et al. (2022). ReAct: Synergizing Reasoning and Acting in Language Models.
- Yeke et al. (2026). Yes-Man (embodied agents refuse only $\sim 16.5\%$).